Rozdział 1

Metody statystyczne do identyfikacji pasm informacyjnych

W tym rozdziale przybliżymy pełną procedurę analizy danych od określenia modelu do identyfikacji informacyjnych pasm częstotliwościowych (ang. informative frequency band, IFB). Określimy postać oraz założenia na temat badanego sygnału, przedstawimy go na wykresach na dwa sposoby, w zależności od występującego w maszynie uszkodzenia lub jego braku. Następnie zdefiniujemy transformatę Fouriera, jej krótkoterminową wersję, przedstawimy jej wyniki na spektrogramie i omówimy różne możliwe przypadki. Na koniec wymienimy, z jakich selektorów będziemy korzystać, aby przeanalizować wynik transformaty w celu odnalezienia IFB.

1.1 Model sygnału drganiowego

Punktem wyjścia naszych analiz jest sygnał reprezentujący drgania pewnej maszyny lub jej części na przestrzeni czasu. Drgania te różnią się w zależności czy maszyna jest bez uszkodzeń (zdrowa) lub z uszkodzeniami (wadliwa). Istnieje ogólne założenie wynikające z obserwacji, że drgania zdrowej maszyny reprezentują gaussowski biały szum. Zdefiniujmy zatem nasz sygnał jako zbiór $\{X_t\}$, gdzie w każdym momencie $t \in T$ naszego pomiaru zachodzi

$$X_t \sim N(0, \sigma). \tag{1.1}$$

Na rysunku 1.1 możemy zobaczyć jak wygląda wykres dla danych reprezentujących zdrową maszynę. W przypadku usterki wśród tego szumu pojawiać się będą okresowo powtarzające się impulsy. Matematycznie zaprezentować je możemy jako sumę wielu funkcji sinusoidalnych, w okolicy jednej częstotliwości. Niech taka funkcja będzie postaci

$$p(t) = \sin(2\pi f_c t)e^{-dt}, \tag{1.2}$$

gdzie f_c jest środkiem pasma częstotliwości, które impuls obejmuje, zaś d jest pewną stałą tłumienia. Ostatecznie zaprezentujemy nasz sygnał z impulsami jako suma białego szumu oraz wielu funkcji sinusoidalnych na pewnym paśmie częstotliwości

$$X_t = N_t + \sum_{k=0}^{N} Ap(t)\mathbb{1}_{[f_{\text{low}}, f_{\text{high}}]}, \tag{1.3}$$

gdzie A to amplituda impulsu, N_t to realizacja zmiennej losowej o rozkładzie normalnym $N(0, \sigma)$, a $\mathbb{1}_{[f_{\text{low}}, f_{\text{high}}]}$ reprezentuje filtrację naszych impulsów ograniczających je tylko do

pasma częstotliwości zawartego między f_{low} oraz f_{high}. Rysunki 1.2 i 1.3 przedstawiają sygnały drgań z dodanymi impulsami o amplitudach odpowiednio 10 i 20 jednostek. Warto tutaj zauważyć jak zmienia się widoczność impulsów po zmniejszeniu amplitudy o połowę. Nawet jeśli na rysunku 1.3 można łatwo odróżnić każdy impuls, to na rysunku 1.2 jest to o wiele trudniejsze. Z tego powodu konieczne jest zastosowanie dodatkowych narzędzi do odnalezienie informacyjnego pasma częstotliwości, które informują o częstotliwości występowania impulsów i tym samym świadczą o wadliwości maszyny.

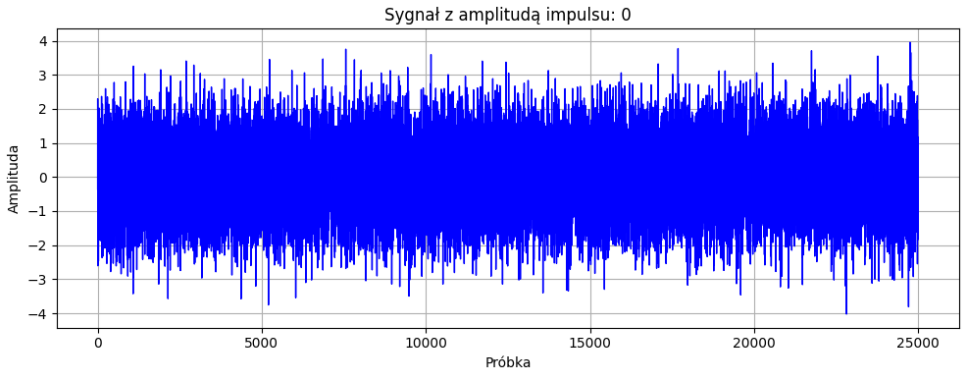

Rysunek 1.1: Sygnał drgań zdrowej maszyny.

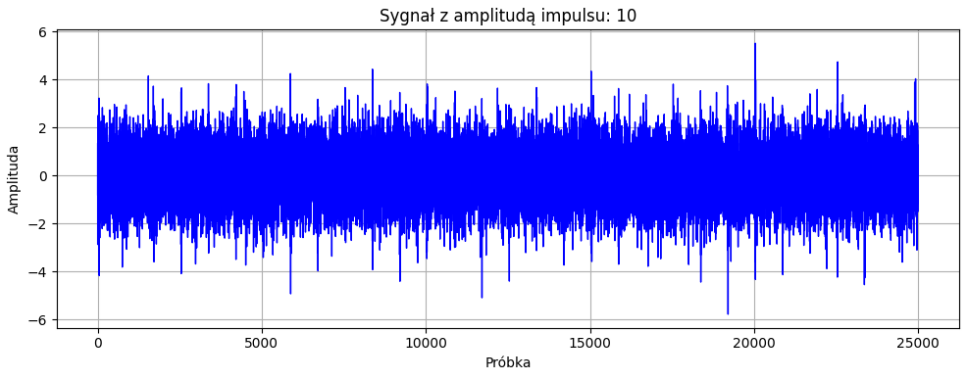

Rysunek 1.2: Sygnał drgań wadliwej maszyny z amplitudą impulsów równą 10.

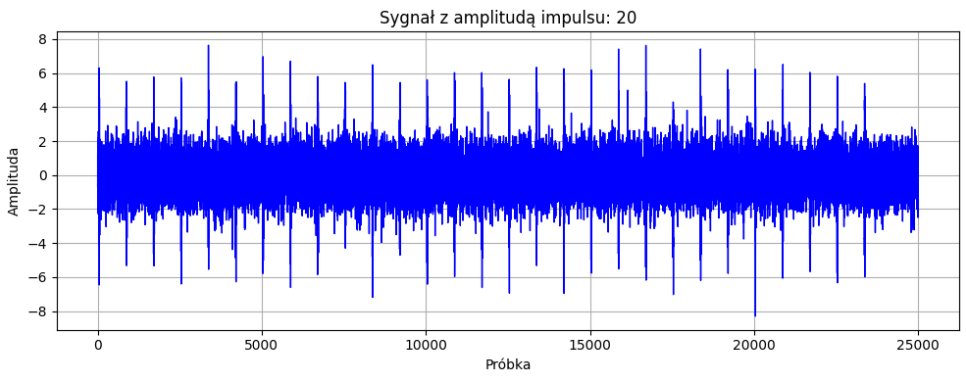

Rysunek 1.3: Sygnał drgań wadliwej maszyny z amplitudą impulsów równą 20.

1.2 Narzędzia wykorzystane do analizy

W tej sekcji przyjrzymy się głównym narzędziom z których będziemy korzystać w naszej pracy. Wpierw przedstawimy definicję transformaty Fouriera oraz spektogramu. Następnie omówimy selektory, które wykorzystamy do celnego wyznaczenia informacyjnych pasm częstotliwości.

1.2.1 Krótkoterminowa transformata Fouriera

Pierwszym i najważniejszym narzędziem, z jakiego będziemy chcieli skorzystać jest transformata Fouriera. Jest to transformacja całkowa, która jako argument wejściowy przyjmuje funkcję rzeczywistą $f(t)$ (np. reprezentującą sygnał), a zwraca nam funkcję zespoloną, która opisuje jak silnie są obecne funkcje zespolone $f_\omega = e^{-i\omega t}$ w pierwotnej funkcji. W praktyce, np. dla sygnału wejściowego otrzymujemy widmo częstotliwości, które informuje nas o tym w jakim stopniu różne częstotliwości występują w pierwotnym sygnale co pozwala łatwo ustalić jego skład.

Głównym celem naszej analizy jest odnalezienie informacyjnego pasma częstotliwości, które zawiera informacje o uszkodzeniu maszyny. Odnajduje się je poprzez analizę wąskopasmowych podsygnałów, które otrzymujemy po rozbiciu sygnału za pomocą transformaty na reprezentację czasowo-częstotliwościową.

W celu uzyskania takich podsygnałów, skorzystamy z krótkoczasowej transformaty Fouriera (STFT), która jest zdefiniowana w następujący sposób[1]:

$$STFT(t, f) = \int_{-\infty}^{\infty} w(t-\tau)X(\tau)e^{2j\pi f\tau}d\tau, \tag{1.4}$$

gdzie $w(t-\tau)$ to przesunięcie okna, a $X(\tau)$ to jest nasz pierwotny sygnał.

W naszych obliczeniach korzystać będziemy z wersji dyskretnej równania (1.4). Dla obserwacji $X_1, X_2, ..., X_N$, punktu czasowego $t \in T$ oraz częstotliwośći $f \in F$ mamy:

$$STFT(t, f) = \sum_{k=0}^{N-1} X_k w(t-k)e^{2j\pi fk/N}. \tag{1.5}$$

1.2.2 Spektrogam

Wynik zastosowania STFT na naszym sygnale będziemy przedstawiać za pomocą spektrogramu. Jest to reprezentacja sygnału, która pokazuje jak zmienia się jego widmo częstotliwości w czasie. Na poziomej osi widnieje częstotliwość, na pionowej czas, a kolor pokazuje amplitudę dla danego zestawienia częstotliwości i czasu, daną jako wartość bezwzględna transformaty $|STFT(t, f)|$. Na rysunku 1.4 widzimy spektrogram dla sygnału bez uszkodzeń.

Po dokonaniu transformaty na sygnale pochodzącym z wadliwej maszyny (rysunek 1.3) oraz narysowaniu spektrogramu (rysunek 1.5), można zauważyć zmiany w amplitudzie w okolicy pasma 2000Hz, występujące co około 0.03s. Ten powstarzający się ślad wnioskuje o uszkodzeniach. Dla porównania, na rysunku 1.6 widać spektrogram dla danych o mniejszej amplitudzie impulsu (rysunek 1.2). Za pomocą transformaty oraz spektrogramu możemy dużo dokładniej określić, czy impulsy występują, a tym samym czy maszyna jest uszkodzona. W rzeczywistości impulsy bywają dużo mniejsze i dlatego będziemy musieli skorzystać z dodatkowych statystyk, zwanych selektorami, aby wyznaczyć pasmo, w którym one występują.

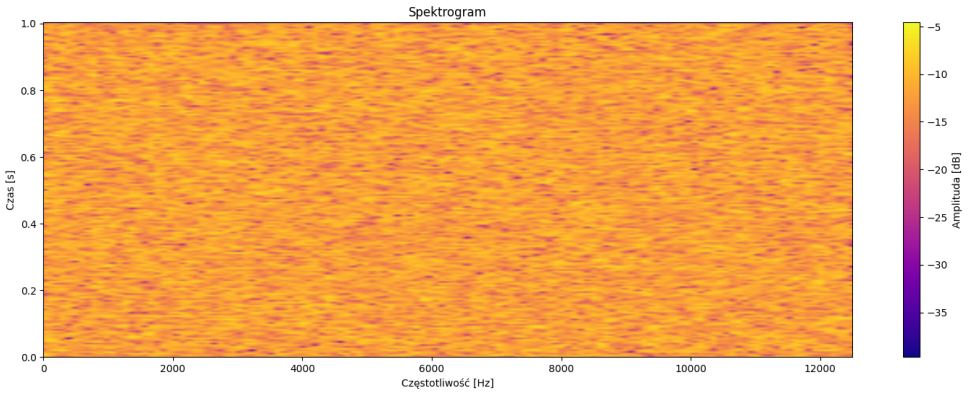

Rysunek 1.4: Spektrogram białego szumu o wariancji równej 5.

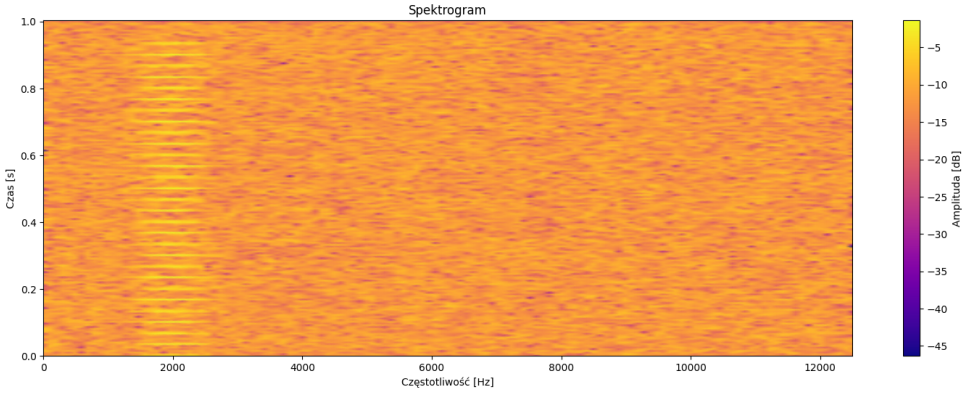

Rysunek 1.5: Spektrogram dla danych z impulsem o amplitudzie 20.

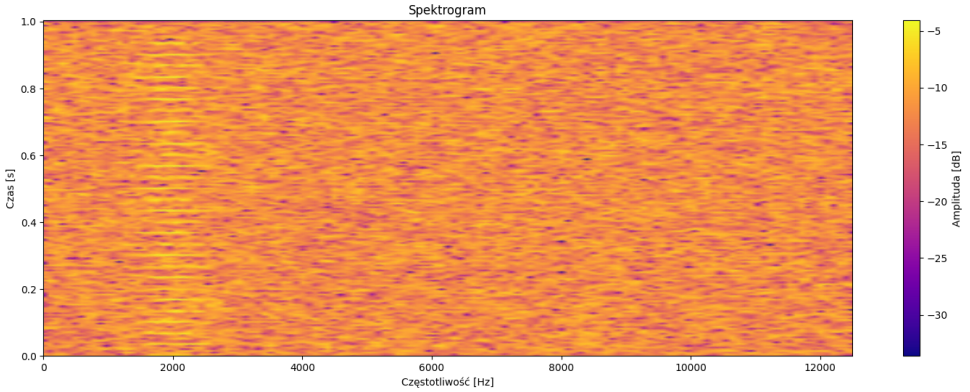

Rysunek 1.6: Spektrogram dla danych z impulsem o amplitudzie 10.

1.2.3 Wybrane selektory informacyjnych pasm częstotliwościowych

Selektorem nazywamy statystykę, która pozwala nam wybrać IFB na podstawie reprezentacji spektrogramowej sygnału. Po dokonaniu krótkoterminowej transformaty Fouriera na sygnale oraz wyrysowaniu spektrogramu, będziemy obliczać wartości tych statystyk dla każdego podsygnału. Wartości te będą w przedziale od 0 do 1, gdzie 1 oznacza zgodność z rozkładem gaussowskim, a 0 niezgodność.

- **Spectral Kurtosis**
  Jako pierwsze przedstawimy popularny wskaźnik w przetwarzaniu sygnałów jakim jest spektralna kurtoza (SK), który według Dwyer'a [2] "nie tylko potrafi wskazać niegaussowskie komponenty w sygnale, ale również ich lokalizację w dziedzinie częstotliwości". Używa się go do identyfikacji niestacjonarnych lub impulsywnych zdarzeń. Dla danej częstotliwości f obliczymy

$$SK(f) = \#T \frac{\sum_{t \in T} |STFT(t,f)|^4}{(\sum_{t \in T} |STFT(t,f)|^2)^2} - 2, \tag{1.6}$$

  gdzie $\#T$ jest wielkością zbioru T. Statystyka ta zwiększa się im bardziej dane odchodzą od danych gaussowskich.

- **Statystyka Jarque-Bera**
  Statystyka Jarque-Bera służy do sprawdzenia, czy skośność i kurtoza zbioru danych pokrywa się z rozkładem gaussowskim. Statystyka ta, obliczona dla odpowiedniego pasma częstotliwości f określa się wzorem [4]

$$JB(f) = \frac{\#T}{6}(S(f)^2 + \frac{(K(f)-1)^2}{4}), \tag{1.7}$$

  gdzie $S(f)$ i $K(f)$ są odpowiednio empiryczną skośnością i kurtozą wyznaczoną dla danego pasma f. Z założenia przyjmujemy że skośność i kurtoza powinny wynosić odpowiednio 0 i 3, według rozkładu gaussowskiego, dlatego każde odstępstwo od tych wartości będzie zwiększało tą statystykę.

- **Statystyka Kolmogorov-Smirnova**

  W następnej kolejności skorzystamy z popularnej statystyki bazującą na empirycznej dystrybuancie, czyli statystyki Kolmogorova-Smirnova[5] . Dla każdego podsygnału f obliczamy

$$KSS(f) = \sup_x |ECDF(f,x) - \Phi(f,x)|, \tag{1.8}$$

  gdzie $\Phi(f,\cdot)$ jest teoretyczną dystrybuantą rozkładu normalnego o parametrach wyznaczonych na podstawie obliczanego podsygnału. Funkcja ta jest dana jako

$$\Phi(f,x) = \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi\sigma(\hat{f})}^2} \exp(-\frac{(x-\mu(\hat{f}))^{2^2}}{2\sigma(\hat{f})})dx \tag{1.9}$$

  gdzie $\mu(\hat{f})$ oraz $\sigma(\hat{f})$ są odpowiednio średnią oraz odchyleniem standardowym obliczonymi na podstawie podsygnału odpowiadającemu częstotliwości f. Z kolej ECDF obliczone jest wzorem

$$ECDF(f,x) = \frac{1}{\#T} \sum_{t \in T} \mathbb{1}\{|STFT(t_k,f)| \leq x\}, \tag{1.10}$$

  gdzie $\mathbb{1}\{A\}$ jest indykatorem zbioru A.

- **Statystyka Anderson-Darlinga**

  Kolejna statystyka rozszerza ideę KSS, albowiem również bazuje na odległości empirycznej dystrybuanty do teoretycznej. Mowa o statystyce Andersona-Darlinga, która należy do rodziny statystyk Cramer-von-Mises. Jest ona określona wzorem

$$Q(f) = \#T \int_{-\infty}^{\infty} (ECDF(f,x) - \Phi(f,x))^2 \phi(x)dx, \tag{1.11}$$

gdzie $\phi(x)$ jest funkcją nakładającą wagi na nasze odległości. Jeśli $\phi(x) = 1$, to statystykę nazywamy Cramer-von-Mises (CVM), zaś jeśli $\phi(x) = [\Phi(f,x)(1-\Phi(f,x))]^{-1}$, to statystykę nazywamy Anderson-Darling(AD).

- **Statystyka Conditional-Variance**

  Ostatni nasz selektor polega na porównywaniu wariancji podzbiorów naszych danych. Oznaczmy, dla pewnego poziomu $0 < q < 0.5$, lewy, prawy oraz środkowy kwantyl naszego zbioru jako

$$\begin{aligned} L_q &:= (-\infty, \Phi^{-1}_{\mu,\sigma}(q)], \quad R_q := [\Phi^{-1}_{\mu,\sigma}(1-q), \infty) \\ M_q &:= (\Phi^{-1}_{\mu,\sigma}(q), \Phi^{-1}_{\mu,\sigma}(1-q)), \end{aligned} \tag{1.12}$$

  gdzie $\Phi_{\mu,\sigma}$ oznacza dystrybuantę rozkładu normalnego o średniej μ i odchyleniu standardowym σ obliczonych na podstawie naszych danych, zaś $\Phi^{-1}_{\mu,\sigma}(d)$ oznacza kwantyl stopnia d. Na podstawie tych założeń oraz dla q bliskiemu 0.2[3] powinniśmy otrzymać

$$\sigma^2_{L_q} = \sigma^2_{M_q} = \sigma^2_{R_q}, \tag{1.13}$$

  gdzie $\sigma^2_A := Var(Y|Y \in A)$. Zasada ta polega na znanej własności rozkładu normalnego, że 20% najmniejszych i 20% największych danych ma tę samą wariancję co pozostałe 60% danych. Na podstawie tej zależności stworzono statystykę sprawdzającą zgodność rozkładu danych z rozkładem gaussowskim

$$N := \frac{1}{\rho}\left(\frac{\hat{\sigma}^2_{L_q} - \hat{\sigma}^2_{M_q}}{\hat{\sigma}^2} + \frac{\hat{\sigma}^2_{R_q} - \hat{\sigma}^2_{M_q}}{\hat{\sigma}^2}\right)\sqrt{n}. \tag{1.14}$$

  Na rysunku 1.7 zobaczyć możemy wyniki zastosowania wszystkich selektorów dla sygnału o amplitudzie impulsów równej 10. Warto tutaj dodać, iż podobne wyniki otrzymalibyśmy dla większych impulsów, co potwierdza skuteczność stosowania selektorów do wyznaczenia informacyjnych pasm częstotliwości.

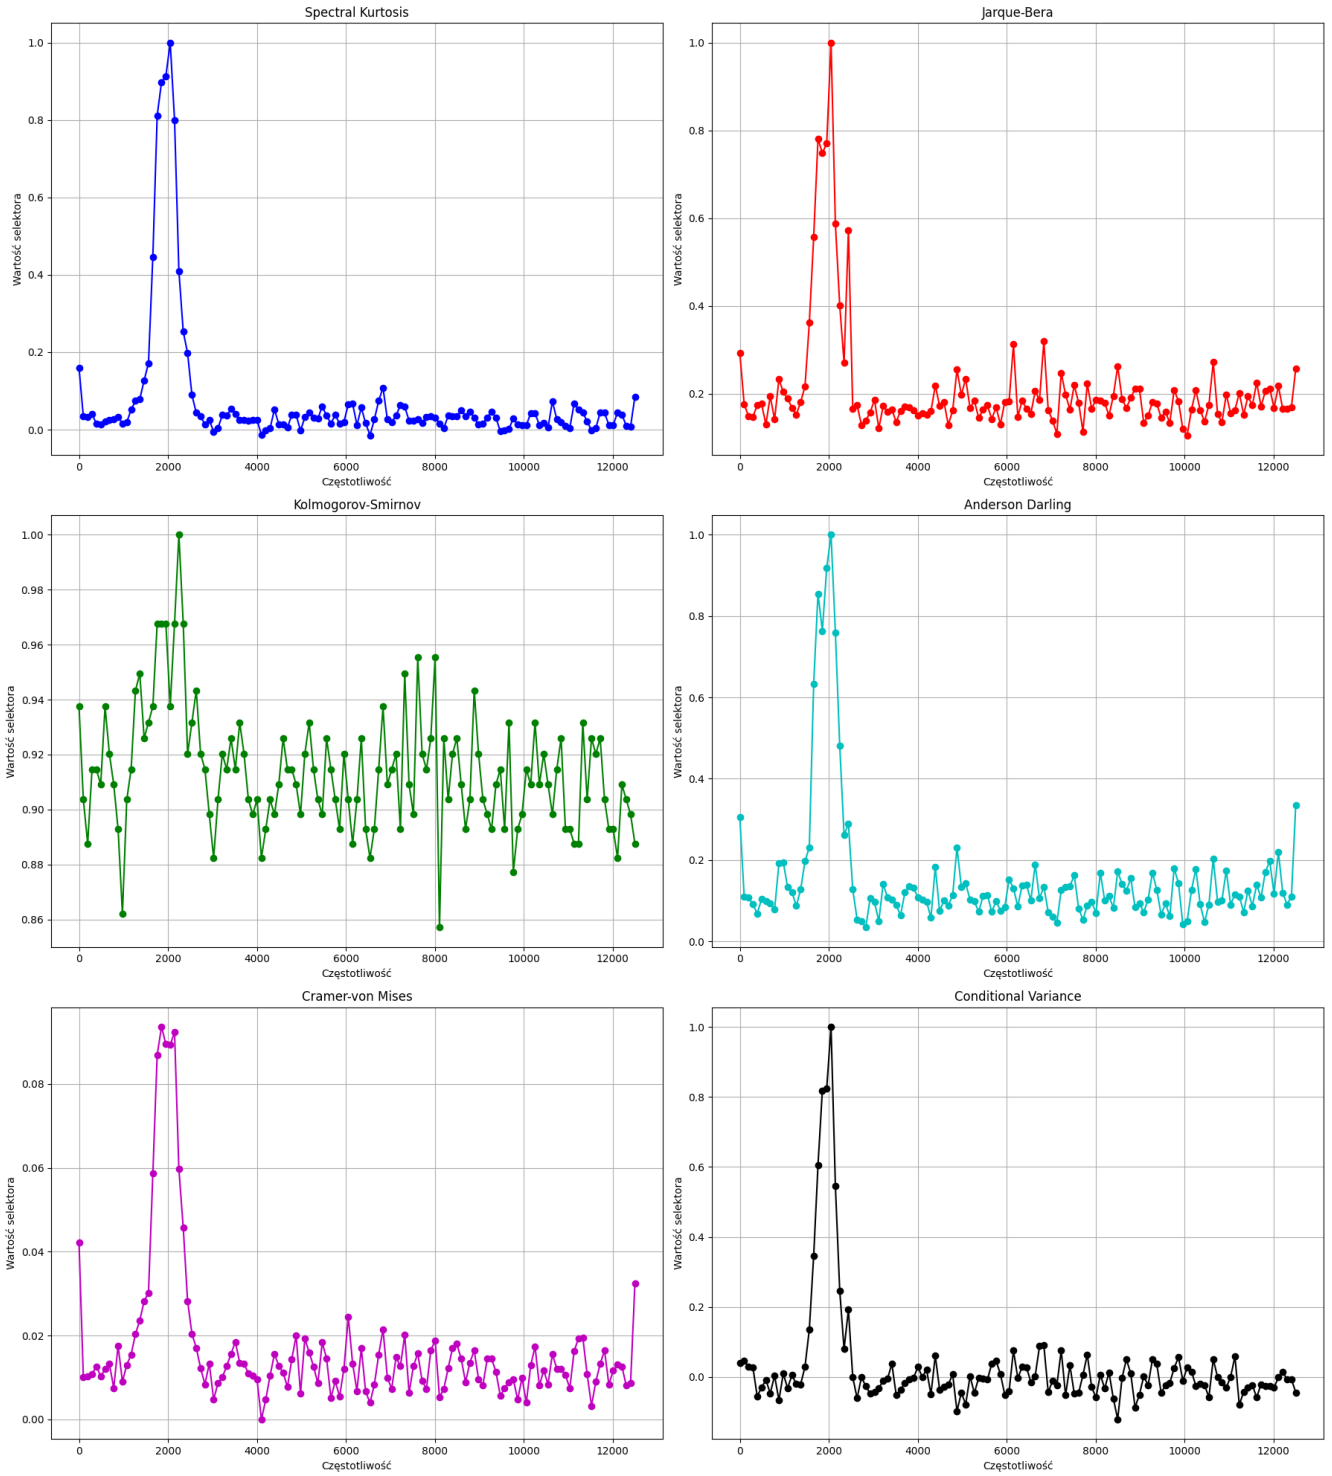

Rysunek 1.7: Wyniki zastosowania selektorów dla sygnału o amplitudzie impulsów 10

Bibliografia

[1] Allen, J. B. Short term spectral analysis, synthesis, and modification by discrete fourier transform. *IEEE Transactions on Acoustics, Speech, and Signal Processing 25*, 3 (1977), 235 – 238. Cited by: 934.

[2] Antoni, J., Randall, R. The spectral kurtosis: application to the vibratory surveillance and diagnostics of rotating machines. *Mechanical Systems and Signal Processing 20*, 2 (2006), 308–331.

[3] Hebda-Sobkowicz, J., Zimroz, R., Pitera, M., Wyłomańska, A. Informative frequency band selection in the presence of non-gaussian noise – a novel approach based on the conditional variance statistic with application to bearing fault diagnosis. *Mechanical Systems and Signal Processing 145* (2020), 106971.

[4] Jarque, C. M., Bera, A. K. Efficient tests for normality, homoscedasticity and serial independence of regression residuals. *Economics Letters 6*, 3 (1980), 255–259.

[5] Justel, A., Peña, D., Zamar, R. A multivariate kolmogorov-smirnov test of goodness of fit. *Statistics Probability Letters 35*, 3 (1997), 251–259.